

Sinalize, Ferramenta para análise preditiva de falhas em transformadores de frequência e potência

**Rodrigo Ramos Guimarães,
Orientadores: Sergio Manuel Serra da Cruz e Jorge Zavaleta**

Programa de Pós-Graduação Em informática – Universidade Federal do Rio de Janeiro (UFRJ)
Rio de Janeiro – RJ – Brasil

Abstract. This paper presents the implementation of a predictive model for anticipating failures in power grid transformers of the main grid of Sistema Interligado Nacional (SIN), operated by Operador Nacional do Sistema Elétrico (ONS). Using Random Forest algorithms and data balancing techniques, the tool named SINALIZE was able to predict failures across different time horizons based on historical characteristics of maintenance, failures, and equipment usage. The results demonstrate the feasibility of applying machine learning techniques to predictive maintenance in electric power systems, contributing to improved reliability, safety, and reduced operational costs. This paper doesn't have institutional relationship with ONS.

Resumo. Este trabalho apresenta a implementação de um modelo preditivo para antecipação de falhas em transformadores da rede básica do Sistema Interligado Nacional (SIN), operado pelo Operador Nacional do Sistema Elétrico (ONS). Utilizando algoritmos de Random Forest e técnicas de balanceamento de dados, a ferramenta, denominada SINALIZE, foi capaz de prever falhas em diferentes horizontes temporais, com base em características históricas de manutenção, falhas e utilização dos equipamentos, demonstrando a viabilidade da aplicação de técnicas de aprendizado de máquina para manutenção preditiva em sistemas elétricos de potência, contribuindo para a melhoria da confiabilidade, segurança e redução de custos operacionais. Este trabalho não tem relação institucional com o ONS.

Palavras-chave: Manutenção Preditiva, Random Forest, Transformadores, Sistema Interligado Nacional

1 Introdução

O Sistema Interligado Nacional (SIN) é um sistema elétrico responsável pela produção e transmissão de energia elétrica no Brasil. Trata-se de um sistema híbrido de grande porte, com predominância de usinas hidrelétricas com múltiplos proprietários, com grande participação da geração térmica, fotovoltaica, eólica, estruturas sistêmicas complexas para a transmissão, e com grande carga regulatória, gerenciado pelo Operador Nacional do Sistema Elétrico (ONS), que conta com quatro centros de operação, cobrindo além de todo território nacional, a importação e exportação de energia para países vizinhos (intercambio internacional).

Esta operação é coordenada através de normas técnicas chamadas Procedimentos de Rede (PR), que garantem a segurança equidade e qualidade do fornecimento de energia.

A rede básica [ONS Procedimentos de Rede - Submódulo 2.1 2024], é composta por um subconjunto de linhas de transmissão e equipamentos de transmissão de energia, com tensão a partir de 230kV, que formam a espinha dorsal do SIN, conectando grandes produtores de energia aos distribuidores, esta estrutura é responsável pela ligação das grandes usinas aos centros de consumo.

A operação deste sistema complexo requer monitoramento contínuo e manutenção adequada de seus componentes críticos, especialmente os transformadores, que são elementos fundamentais para a transmissão. As falhas destes equipamentos, podem resultar em interrupções significativas no fornecimento de energia, causando prejuízos econômicos e sociais consideráveis. Conforme os procedimentos de Rede, a manutenção destes equipamentos segue estratégias preventivas (baseadas em cronogramas fixos) ou corretivas (após a ocorrência de falhas). No entanto, a evolução das tecnologias de análise de dados e aprendizado de máquina traz oportunidades para implementação de estratégias de manutenção preditiva mais eficientes.

Este trabalho propõe o desenvolvimento de um modelo preditivo baseado em Random Forest para antecipação de falhas em transformadores da rede básica do SIN. O modelo utiliza dados

históricos de manutenção, falhas e utilização dos equipamentos¹ para prever a probabilidade de falhas em diferentes horizontes temporais, permitindo a otimização de estratégias de manutenção, melhorando a confiabilidade do sistema e economizando recursos financeiros para os agentes e sociedade, recursos estes que em 2022, pagos como penalização pelos agentes, somaram mais de R\$ 48Mi [ONS - SOM] , dinheiro poderia ser utilizado em melhorias significativas na rede, sem considerar o custo intangível da sociedade sem energia em diversas ocasiões.

2 Revisão de Literatura

A aplicação de técnicas de aprendizado de máquina em sistemas elétricos de potência tem crescido significativamente nos últimos anos. Diversos estudos² demonstram a eficácia de algoritmos como Random Forest, Support Vector Machines e Redes Neurais na predição de falhas em equipamentos elétricos, contudo, tais estudos apresentam limitações quanto à cobertura de dados, utilizando primariamente dados com escopo local, com acesso limitado à dados de múltiplos agentes e equipamentos, tornando mais difícil obter respostas assertivas.

O Random Forest, proposto por [Breiman 2001], é um algoritmo versátil, que combina múltiplas árvores de decisão para melhorar a precisão e robustez das previsões. Sua adequação pra aplicações desta natureza, se dá pela capacidade de lidar com dados não-lineares, resistência ao sobreajuste, facilidade de implementação e interpretação dos resultados.

¹ Dados descaracterizados originário de sistema interno de uma empresa do setor elétrico, para mais informações vide sessão de proveniência de dados.

² Fault Detection and Prediction for Power Transformers — B. C. Mateus et al., 2024,
Power Transformer Health Index and Life Span Assessment: A Comprehensive Review of Conventional and Machine Learning based Approaches — Syeda T. Zahra et al., 2025

3 Metodologia

O trabalho consiste na coleta e preparação dos dados, cruzamento com séries de utilização de equipamentos e registros de ocorrências de falhas, dados estes que passaram por um processo de descaracterização, tornando impossível a identificação de registros reais. Estes processos estão detalhados nas demais sessões deste trabalho.

3.1 Coleta de dados

Os dados foram coletados e tratados em um processo de ETL, que entrega seus datasets finais na pasta RAW do projeto, permitindo a reprodução do estudo, incluindo futuros trabalhos e evoluções. Os seguintes datasets foram utilizados:

- Cadastro de transformadores
- Dados de manutenções preventivas
Desligamentos programados para manutenção preventiva e atividades mínimas de manutenção
- Dados de ocorrências de falhas nos equipamentos
Dados de perturbações do sistema, ocorrem quando há uma falha em um equipamento
- Séries temporais, de utilização (carga) de equipamentos
Dados extraídos do sistema de supervisão e controle, em formato de séries temporais por ampere e minuto a minuto

Com objetivo de garantir maior qualidade dos dados, o período de análise foi limitado a partir de janeiro de 2023. Foram considerados apenas equipamentos que possuíam registros de manutenção, resultando em um conjunto de dados balanceado e representativo.

3.2 Criação de features

Foi desenvolvido um processo de ETL para extrair datasets em formato de features a partir dos dados brutos. Os seguintes itens se mostraram aderentes ao desenho da solução:

- Features de Características do Equipamento
 - idade_dias: Idade do equipamento em dias, média utilizando a data de entrada em operação comercial;
 - limite_potencia: Limite nominal de potência do equipamento;
- Features de Histórico de Manutenção
 - dias_desde_ultima_manut: Dias transcorridos desde a última manutenção preventiva do equipamento;
 - num_anutencoes: Quantidade total de manutenções preventivas realizadas no equipamento;
 - intervalo_medio_manut: Intervalo médio em dias em que as manutenções são realizadas nos equipamentos;
- Features de Falhas
 - num_falhas_historico: Número de falhas históricas do equipamento
 - taxa_falhas_ano: Taxa anualizada de falhas
 - minutos_falha_historico: Total de minutos em que o equipamento esteve em falha
 - taxa_minutos_falha_ano: Taxa anualiza de minutos em falha
- Features de utilização dos equipamentos
 - utilizacao_media: Utilização média do equipamento no mês
 - utilizacao_maxima: Pico de utilização do equipamento no mês
 - utilizacao_minima: Mínimo de utilização do equipamento no mês
 - qtd_sobrecargas: Número de violações de limite do equipamento

3.3 Definição do objetivo do modelo

O objetivo foi definido como uma variável denominada: **vai_falhar** que indica se o equipamento apresentará falha com base no tamanho do período de base, especificado de X dias. Esta abordagem permite ao modelo aprender padrões que precedem as falhas, possibilitando intervenções preventivas.

3.4 Tratamento para balanceamento de dados

Como as falhas em transformadores são eventos relativamente raros, são produzidas classes desbalanceadas. Para tratar estes casos, foi utilizado a técnica SMOTE [Chawla et al., 2002], que basicamente cria amostras intermediárias através da interpolação de dados vizinhos. Técnica esta, que aumentou consideravelmente a performance geral do modelo

3.5 Escolha do Algoritmo Random Forest

A escolha do Random Forest como algoritmo principal foi baseada em suas vantagens específicas para o problema aqui tratado, pois diferente de modelos de árvore de decisão tradicionais, ele combina múltiplas árvores e seleção aleatória de features, reduzindo o risco de sobreajuste (overfitting), o que na prática, significa que mesmo com dados históricos de exemplo mais raros, ele não irá decorar o dado, entendendo ruídos como casos reais, além de lidar bem com features numéricas sem necessidade de pré-processamento extensivo, na contramão de SVMs, que demandam normalização dos dados de forma extensiva. O Random Forest também demanda menos poder computacional para trabalhar, facilitando a geração de treinamentos para testes e ajuste fino do modelo.

3.6 Configurações e Parâmetros do Modelo

A implementação do RandomForest, foi realizada utilizando o pacote sklearn, cos seguintes elementos:

Table 1. Listagem de versões de componentes utilizados no modelo

Componente	Detalhes / versão
Hardware	Macbook Pro M1 32 GB RAM
Sistema Operacional	MACOS 15.6 (24G84)
Pyhon	3.11.7
pandas	2.3.3

numpy	1.26.4
scikit-learn	1.2.2
joblib	1.2.0
flask	3.0.0

- n_estimators: 100,1000
 - Define o número de árvores na floresta, mais árvores tendem a melhorar a estabilidade e a generalização do modelo.
- max_depth: 10,20,30
 - Controla a profundidade máxima das árvores. Árvores mais profundas capturam padrões mais complexos, mas podem gerar problemas de overfitting
- min_samples_split: 2,5
 - Número mínimo de amostras necessário para dividir um nó, valores maiores tornam o modelo mais conservador ajudando a evitar divisões baseadas em poucos dados (ruído), mas valores pequenos podem não pegar casos reais diminuindo a performance do modelo
- class_weight: balanced
 - Ajusta automaticamente os pesos das classes de forma inversamente proporcional à sua frequência, é essencial em problemas com classes desbalanceadas, como falhas raras em equipamentos. Evita que o modelo favoreça apenas a classe majoritária.

3.7 Otimização com Grid Search e validação cruzada

O Grid Search testa todas as combinações possíveis desses parâmetros e seleciona aquela que apresenta o melhor desempenho segundo a métrica definida (ex.: F1-score, ROC-AUC), e na validação cruzada, os dados são divididos em 5 subconjuntos (folds), e em cada iteração 4 são usados para treino e um para validação, forçando que a proporção de classes seja mantida em todos os folds, como benefícios desta abordagem temos:

- Avaliação mais confiável do desempenho do modelo;
- Redução do risco de overfitting;
- Melhor generalização para dados.

3.8 Métricas de avaliação


O desempenho do modelo foi avaliado utilizando as seguintes métricas:

- ROC-AUC: Área sob a curva ROC, medindo a capacidade de discriminação;
- Precision: Proporção de previsões positivas corretas;
- Recall: Proporção de casos positivos corretamente identificados;
- F1-Score: Média harmônica entre precision e recall;
- Accuracy: Proporção total de previsões corretas.

4 Resultados

4.1 Características do dataset final

O dataset final, gerado na pasta gold, compreendeu equipamentos válidos (com histórico de manutenção e falhas), com distribuição variável de falhas dependendo do horizonte temporal analisado.

Fig. 1. Distribuição de Falhas vs total de equipamentos por período de dias


Fonte: Produzido pelo autor

4.2 Importância das Features

A análise de importância das features confirma a intuição técnica sobre os fatores que influenciam falhas em transformadores. A predominância da taxa histórica de falhas como preditor principal sugere que equipamentos com histórico problemático tendem a continuar apresentando falhas, validando a abordagem baseada em dados históricos.


O tempo desde a última manutenção emerge como segundo fator mais importante, reforçando a importância de estratégias de manutenção preventiva adequadas. A idade do equipamento, de maneira contraintuitiva, aparece em quarto lugar, indicando que os equipamentos mais novos tendem a apresentar defeitos em número maior que equipamentos mais antigos, e indicando que o histórico operacional acaba sendo mais relevante que o tempo de uso do equipamento, o que é um possível indicativo de obsolescência programada

Fig. 2. Features mais importantes (média períodos)



Fonte: Criado pelo Autor

Fig. 3. Mapa de calor das features (40 dias)




4.3 Análise final sobre a escolha do modelo

A capacidade de fornecer dados interpretáveis de importância das features confirmou a escolha do Random Forest sobre alternativas como redes neurais profundas. Esta facilidade de interpretar os resultados, permitiu os especialistas da empresa, analisarem os resultados e validarem maneira preliminar, os aspectos técnicos e precisão dos resultados, em detrimento a outros algoritmos que trabalham no formato de “caixa-preta”, que não oferecem esta visão, que facilita muito a interpretação e confiança no modelo.

4.4 Performance

Os resultados demonstram performance consistente e crescente com o aumento do horizonte temporal, indicando conforme o esperado, que o modelo é mais eficaz na predição de falhas em períodos mais longos.

Fig. 4. Métricas do modelo por período (Precision, Recall e F1)



Fonte: Produzido pelo autor

4.5 Análise de casos de exemplo

Dados de probabilidade extraídos da API³:

- Baixa probabilidade de falhas:

Equipamento: EA32ACF8-6379-4AD9-BD8D-14D4F18CAFA3
Probabilidade de Falha: 0.01%
Falhou na realidade: NÃO
- Idade: 4284 dias (11.7 anos)
- Manutenções: 3
- Dias desde última manutenção: 296
- Falhas históricas: 2
- Utilização média: 44.0%
- Sobrecargas: 5

- Alta probabilidade de falhas

³ Dados extraídos da API contida no repositório GIT do projeto

Equipamento: D28C46DC-BF3E-41DE-AD8D-98E577997D49

Probabilidade de Falha: 98.0%

Falhou na realidade: SIM

- Idade: 9893 dias (27.1 anos)

- Manutenções: 6

- Dias desde última manutenção: 107

- Falhas históricas: 2

- Utilização média: 75.9%

- Sobrecargas: 1

4.6 Limitações e oportunidades de melhoria

O modelo apresenta algumas limitações a serem consideradas.

- Dados de fatores ambientais e climáticos

Não foram considerados dados de fatores ambientais, como temperatura média, umidade, índice UV, vento e fatores de queimadas, estes dados podem ser adicionados para estudos futuros;

- Dados de monitoramento do equipamento

Existem outros dados de monitoramento dos equipamentos, que não foram considerados no estudo, como temperatura e características internas, marca do óleo, modelo de placa de comunicação, fabricante do equipamento etc.;

- Detalhamento das falhas

Existem em sistemas internos, dados de detalhamento das falhas, indicando qual foi o componente que causou a falha, estes dados não foram considerados.

5 Conclusões

Este trabalho demonstrou que é viável a aplicação de técnicas de aprendizado de máquina para prever falhas em equipamentos, mais especificamente transformadores. Mesmo não apresentando performance satisfatória em horizontes temporais de curto prazo, obteve

em geral ROC-AUC variando de 0.847 a 0.879, em uma validação empírica com dados reais do sistema elétrico descaracterizados.

Dentre as contribuições do trabalho, pode-se destacar pontos como uma metodologia sólida, pois o pipeline de dados trata dados brutos, extraídos diretamente dos sistemas de origem, gerando os arquivos de features, adaptáveis a outros tipos de equipamentos e cenários com pouco desenvolvimento, confirmando a possibilidade de expandir o estudo para outros tipos de equipamentos, como linhas de transmissão, bancos de capacitores, equipamentos de controle reativo, e até mesmo na parte de geração com usinas e unidades geradores.

E como contribuição à sociedade, o modelo já contempla de partida, uma API para simulação de casos especiais, habilitando a utilização produtiva, e integração com sistemas de gestão internos.

6 Trabalhos futuros

Dentre as principais evoluções do modelo, destacam-se:

- Dados de meteorologia
A carga de dados de meteorologia ao modelo, agrupa novas possibilidades de fatures a serem analisadas, como temperatura média, vendo, índice UV e até incidência de raios na região do equipamento. Os dados estão disponíveis em dataset já formatado e serão tratados em demandas futuras, porém, devido à dificuldade para descaracterização, não foi possível a utilização neste momento.
- Mais metadados de equipamentos
Adicionar mais propriedades de equipamentos, como fabricante das placas controladoras, modelo detalhado, marca, fabricante, temperatura média de utilização, existe em alguns casos até o datasheet do equipamento, que pode ser indexado via web scrapping no futuro;
- Categorização do detalhamento das falhas via LLM

Caso haja detalhamento textual, criado pelos engenheiros da empresa, com a descrição da falha, indicação da causa e impactos em outros equipamentos, este texto pode ser tratado utilizando uma LLM e categorizando para novas features do modelo a serem analisadas;

Referencias

[Glossário ONS 2025] OPERADOR NACIONAL DO SISTEMA ELÉTRICO (ONS). Glossário de termos do setor elétrico. Disponível em: <https://www.ons.org.br/paginas/conhecimento/glossario>. Acesso em: 10 nov. 2025.

[ONS - que é o SIN 2025] OPERADOR NACIONAL DO SISTEMA ELÉTRICO (ONS). O que é o SIN? Disponível em: <https://www.ons.org.br/paginas/sobre-o-sin/o-que-e-o-sin> Acesso em: 10 nov. 2025.

[ONS Procedimentos de Rede - Submódulo 2.1 2024] OPERADOR NACIONAL DO SISTEMA ELÉTRICO (ONS). Procedimentos de rede – submódulo 2.1 – Definição das redes do Sistema Interligado Nacional Disponível em <https://www.ons.org.br/paginas/sobre-o-ons/procedimentos-de-rede/vigentes> Acesso em 13 nov. 2025.

[ONS - SOM] OPERADOR NACIONAL DO SISTEMA ELÉTRICO (ONS). Síntese da operação mensal – disponível em: <https://www.ons.org.br/paginas/conhecimento/acervo-digital/documentos-e-publicacoes> Acesso em: 10 nov. 2025.

[ONS Procedimentos de Rede - Submódulo 16.1 2024] OPERADOR NACIONAL DO SISTEMA ELÉTRICO (ONS). Procedimentos de rede – submódulo 16.1 – Acompanhamento de manutenção – Visão Geral Disponível em <https://www.ons.org.br/paginas/sobre-o-ons/procedimentos-de-rede/vigentes> Acesso em 13 nov. 2025.

[Breiman 2001] Breiman, L. Random Forests. *Machine Learning* 45, 5–32 (2001). <https://doi.org/10.1023/A:1010933404324>

[B. C. Matheus et al 2024] Fault Detection and Prediction for Power Transformers <https://www.mdpi.com/1996-1073/17/2/296>

[Syeda T. Zahra et al., 2025] Power Transformer Health Index and Life Span Assessment: A Comprehensive Review of Conventional and Machine Learning based Approaches — Syeda T. Zahra et al., 2025

[Chawla et al., 2002] Chawla, N.V., Bowyer, K.W., Hall, L.O., Kegelmeyer, W.P. SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research* 16, 321–357 (2002). <https://doi.org/10.1613/jair.953>