

Sin@lize: Uma Ferramenta de Análises Preditivas de Falhas em Transformadores de Potência

Rodrigo Ramos Guimarães¹, Jorge Zavaleta³,
Maria Luiza Machado Campos^{1,2}, Sergio Manuel Serra da Cruz^{1,2}

¹Programa de Pós-Graduação em Informática (PPGI) – Universidade Federal do Rio de Janeiro (UFRJ) – Rio de Janeiro – RJ – Brasil

²Instituto de Computação – Universidade Federal do Rio de Janeiro (UFRJ)
Cidade Universitária – CEP 21941-853 – Rio de Janeiro – RJ – Brasil

³Departamento de Ciências Ambientais – Universidade Federal Rural do Rio de Janeiro (UFRRJ) – BR-465, Km 7, CEP 23897-000 – Seropédica – RJ – Brasil

rrg@ufrj.br, zavaleta@pet-si.ufrrj.br,
{marialuiza, sergioserra}@ic.ufrj.br

Abstract. *This paper presents a dataset and a tool based on predictive models for anticipating failures in power transformers of the main grid of the National Interconnected System (SIN) operated by the National Electric System Operator (ONS). The tool, named Sin@lize, utilizes ETL pipelines, machine learning, and data balancing techniques to predict failures across different time horizons, based on historical characteristics of maintenance data, failures, and equipment usage. The initial results of the tool demonstrated the feasibility of applying Random Forest (RF), XGBoost and a RF+XGBoost Ensemble for predictive maintenance decisions in electric power systems, potentially contributing to improved reliability, safety, and reduced operational costs.*

Resumo. *Este trabalho apresenta o dataset e a ferramenta baseada em modelos preditivos para antecipação de falhas em transformadores de potência da rede básica do Sistema Interligado Nacional (SIN) operado pelo Operador Nacional do Sistema Elétrico (ONS). A ferramenta denomina-se Sin@lize utiliza, pipelines ETL, aprendizado de máquina e técnicas de balanceamento de dados para prever falhas em diferentes horizontes temporais, com base em características históricas dos dados de manutenção, falhas e utilização dos equipamentos. Os primeiros resultados da ferramenta evidenciaram a viabilidade da aplicação de Random Forest (RF), XGBoost e um Ensemble RF+XGBoost para decisões em manutenção preditiva em sistemas elétricos de potência, podendo contribuir para a melhoria da confiabilidade, segurança e redução de custos operacionais.*

1. Introdução

O Sistema Interligado Nacional (SIN) é a infraestrutura responsável pela geração e transmissão de energia elétrica no Brasil, tratando-se de um dos maiores sistemas do mundo que cobre cerca de 96% da capacidade instalada de produção de energia do país. O Brasil optou por um modelo interconectado e híbrido composto por fontes hidrotérmico-eólico-solar-nuclear. SIN possui estruturas complexas para apoiar a geração

e transmissão de energia, ambas estão sujeitas a grande carga regulatória sendo gerenciados pelo Operador Nacional do Sistema Elétrico (ONS), que atua por meio de quatro centros de operação, cobrindo além de todo território nacional, a importação e exportação de energia para países vizinhos [ONS 2025].

No SIN, os transformadores de potência são considerados componentes críticos e suas falhas podem causar interrupções significativas, penalidades consideráveis prejuízos econômicos e sociais, por exemplo, somente em 2022, os custos de penalidades devido as falhas no sistema ultrapassaram R\$ 48 milhões [ONS - SOM]. Atualmente, a gestão de ativos no SIN baseia-se predominantemente em manutenções programadas (PR) e em estratégias preventivas, orientadas por cronogramas de manutenções fixas ou corretivas, disparadas após a ocorrência de falhas. No entanto, segundo Huang e Wang (2020) e Porawagamage et al. (2024), essas manutenções mostram-se limitadas diante da natureza multivariada e não linear dos modos de falha em transformadores de potência. A manutenção preventiva pode gerar intervenções desnecessárias, enquanto a corretiva impõe custos elevados de indisponibilidade e reparos emergenciais [Huang e Wang, 2020].

Os avanços em IA possibilitam a transição para uma manutenção preditiva orientada por dados. Tal evolução permite identificar padrões de degradação imperceptíveis ante as análises convencionais, antecipando falhas de forma precisa e otimizando o ciclo de vida dos ativos do SIN. Este trabalho tem como objetivo apresentar a ferramenta Sin@lize e seus *datasets* que apoiam a manutenção preditiva baseada em algoritmos de aprendizado de máquina que antecipam falhas em transformadores de potência da rede do SIN.

Os experimentos de avaliação utilizaram séries de dados históricos de manutenção, falhas e uso dos equipamentos do SIN. O modelo oferece como resultados a previsão das probabilidades de falhas dos equipamentos em diferentes horizontes temporais, possibilitando que a ONS otimize seus procedimentos de manutenção, aumentando ainda mais a confiabilidade do SIN e com possibilidade de redução de custos para os agentes e sociedade.

Este *dataset paper* está organizado da seguinte forma, além da Introdução, a Seção 2 apresenta os trabalhos relacionados a Sin@lize. A Seção 3 descreve os materiais e métodos. A Seção 4 apresenta o *dataset*, geração e experimentos. A Seção 5 reúne as considerações finais.

2. Trabalhos Relacionados

A aplicação de técnicas de aprendizado de máquina em Sistemas Elétricos de Potência (SEP) tem crescido significativamente, estudos recentes demonstram a eficácia de algoritmos como *Random Forest (RF)*, *Support Vector Machines (SVM)* e *Redes Neurais Artificiais (RNA)* na predição de falhas [Huang e Wang, 2020; Heidari et al., 2024 e Porawagamage et al. (2024)].

Atualmente, grande parte da literatura especializada foca em bases de dados de escopo local ou ensaios laboratoriais, o que limita a generalização dos modelos para a escala do SIN, onde a diversidade de agentes, distribuição geográfica e condições operacionais são complicadores.

O RF destaca-se por ser um método de *ensemble* que combina múltiplas árvores de decisão, mitigando problemas de *overfitting* e oferecendo maior robustez a ruídos nos dados, características comuns em registros de manutenção em SEPs [Breiman, 2001 e Huang e Wang, 2020]. Diferente de uma árvore de decisão convencional, o RF opera sobre subconjuntos aleatórios do espaço de características (*feature space*), o que o torna eficaz na manipulação de grandes volumes de atributos heterogêneos, como por exemplo, a idade do ativo, parâmetros operacionais, histórico de carga e localização geográfica dos transformadores, entre outros.

Já o XGBoost (Extreme Gradient Boosting) [Chen e Guestrin, 2016] representa uma visão complementar, enquanto o RF treina árvores em paralelo com subconjuntos de dados de forma aleatória, o XGBoost constrói árvores de forma sequencial, focando nos erros residuais de iterações anteriores. Essa estratégia confere ao XGBoost uma maior sensibilidade de decisão, especialmente em *datasets* altamente desbalanceados, contexto recorrente em séries de falhas de equipamentos da ONS.

Abordagens *Ensemble* que combinam mais de um algoritmo têm demonstrado ganhos adicionais, ao diversificar os vieses individuais de cada algoritmo [Syeda T. Zahra et al., 2025], cuja seleção estocástica de variáveis dos transformadores de potência permite capturar correlações complexas sem que os modelos se tornem excessivamente sensíveis a variáveis irrelevantes. Além disso, a sua capacidade em mensurar a importância das variáveis (*feature importance*) agrega um valor estratégico às análises, permitindo identificar quais indicadores operacionais são os principais preditores de falha [Chen, Ciu e Luo, 2011]. Essa interpretabilidade fornece subsídios valiosos para o refinamento das políticas de monitoramento e a priorização de intervenções nos ativos mais críticos antes da ocorrência de falhas.

A despeito dos avanços presentes na literatura mundial, observa-se uma lacuna em estudos aplicados à realidade brasileira voltados ao SIN. Embora existam iniciativas isoladas em concessionárias locais de energia focando na detecção de falhas [Matheus et al., 2024], nossa proposta se diferencia das demais, ela está focada na antecipação da ocorrência de falhas através de múltiplos horizontes temporais.

3. Materiais e Métodos

A metodologia adotada neste trabalho não é apenas teórica, pelo contrário é de natureza experimental e quantitativa, seguindo o *framework* de Ciência de Dados Aplicada [Geron 2025]. Ele envolve diversas etapas de um ciclo se iniciam na coleta de dados brutos nos sistemas da ONS. As etapas estão detalhadas nas próximas subseções, assim como os detalhes quantitativos e qualitativos do *dataset*.

3.1. Coleta de dados

Os dados brutos são relativos aos transformadores de potência do SIN que possuíam algum registro de manutenção preventiva ou corretiva, os dados utilizados nestes estudos são referentes ao período de 01 de janeiro de 2023 até 31 de dezembro de 2025.

O processo de coleta de dados transcorreu através de *pipelines* ETL codificados em Python para gerar os *datasets* e armazená-los em uma pasta RAW temporária. Ressaltamos que devido à natureza sensível dos dados da ONS, estes foram submetidos a processos de descaracterização dos identificadores dos clientes e localização dos equipamentos.

A estrutura dos *datasets* inclui: cadastro de transformadores de potência; informações de manutenções preventivas e corretivas; informações sobre desligamentos programados para manutenção preventiva e atividades mínimas de manutenção; dados de ocorrências de falhas nos equipamentos; dados de perturbações do sistema que ocorrem quando há uma falha em um equipamento; séries temporais de utilização de carga dos equipamentos e limites sistêmicos de equipamentos. O *dataset* possui os arquivos indicados na Tabela 1.

Tabela 1: Caracterização do dataset

Arquivo	No. Registros	No. Colunas	Contexto
Falhas.csv	3.892	5	Dados de desligamentos automáticos ou emergenciais por falhas em equipamentos
Manutenção.csv	7.472	4	Dados de desligamentos para manutenção preventiva de equipamentos
Transformadores.csv	1.559	4	Listagem de todos os transformadores da rede básica do SIN
Limites.csv	7.400	2	Registros de dados de limites dos equipamentos. Os limites podem mudar por questões operativas
UtilizacaoTransformadores (1.559 arquivos)	240.136.102	2	Carga do equipamento em ampere por instantes de 15 minutos

3.2. Criação do *features space*

O pipeline ETL produziu *datasets* com as *features* necessárias para o Sin@lize. A Tabela 2 apresenta as *features* e suas respectivas descrições.

Tabela 2: Descrição das features do Modelo Preditivo

Categoria	Feature (Variável)	Descrição
Características do Equipamento	<i>idade_dias</i>	Idade do equipamento em dias, calculada a partir da data de entrada em operação comercial.
	<i>limite_potencia</i>	Limite nominal de potência do equipamento.
Histórico de Manutenção	<i>dias_desde_ultima_manut</i>	Dias transcorridos desde a última manutenção preventiva.
	<i>num_manutencoes</i>	Quantidade total de manutenções preventivas realizadas no equipamento.
	<i>intervalo_medio_manut</i>	Média de dias entre as manutenções realizadas.
Histórico de Falhas	<i>num_falhas_historico</i>	Número total de falhas históricas registradas para o equipamento.
	<i>taxa_falhas_ano</i>	Taxa anualizada de ocorrência de falhas.
	<i>minutos_falha_historico</i>	Tempo total acumulado (em minutos) em que o equipamento esteve fora de operação por falha.
	<i>taxa_minutos_falha_ano</i>	Taxa anualizada de tempo de indisponibilidade por falha.
	<i>dias_desde_ultima_falha</i>	Dias transcorridos desde a última falha
Utilização do Equipamento	<i>utilizacao_media</i>	Utilização média mensal do equipamento.
	<i>utilizacao_maxima</i>	Pico de utilização (carga máxima) registrado no mês.
	<i>utilizacao_minima</i>	Valor mínimo de utilização registrado no mês.
	<i>utilizacao_desvio</i>	Desvio padrão de carga no período
	<i>taxa_sobrecargas_ano</i>	Taxa anual de violações de limites nominais de operação do equipamento
	<i>qtd_sobrecargas</i>	Número de violações dos limites nominais de operação do equipamento.

	<i>p90_utilizacao</i>	Percentil 90 de utilização histórica do equipamento
	<i>delta_utilizacao</i>	Diferença entre a média dos 90 dias e histórico total, indica se está havendo pico de uso recente
	<i>utilizacao_tendencia_90d</i>	Tendencia linear de utilização 90 dias
	<i>dias_acima_80pct_limite</i>	Dias em que o Trafo ficou acima dos 80% do limite

3.3. Objetivo e Balanceamento de Dados

O objetivo foi definido como uma variável denominada “vai_falhar”. A variável indicará se o equipamento falhará com base intervalo de tempo especificado de até 90 dias. Esta condição permite ao modelo aprenda os padrões que precedem as falhas, possibilitando intervenções preventivas.

As falhas em transformadores de potência são eventos raros, eles produzem classes desbalanceadas. No modelo RF, para tratar esses casos, utilizou-se a técnica SMOTE [Chawla et al., 2002] no conjunto de dados de treino, que gera amostras intermediárias através da interpolação de dados de vizinhos próximos, enquanto o XGBoost, possui o parâmetro (*scale_pos_weight*) que ajusta o peso das classes minoritárias proporcionadas ao desbalanceamento, indicando ser mais compatível com a estratégia de árvores sequenciais.

3.4. Aprendizado de Máquina e Escolha de Hiperparâmetros

Com base na revisão literária, dois algoritmos foram selecionados para *benchmark*: Random Forest (RF) e XGBoost. Ambos se adequam bem aos cenários da ONS, com dados heterogêneos e classes desbalanceadas, mas com estratégias distintas. O RF opera por *bagging* e paralelismo com amostragens em pedaços, enquanto o XGBoost opera por construção sequencial focada em resíduos de erros, com maior capacidade de capturar padrões sutis próximos ao limite da detecção.

A implementação foi realizada utilizando as bibliotecas Python scikit-learn (RF) e xgboost (XGB). Os hiperparâmetros submetidos ao processo de otimização via Grid Search estão detalhados nas tabelas 3 e 4.

Tabela 3: Espaço de Busca de Hiperparâmetros para o RF

Hiperparâmetros	Valores Testados	Descrição e Justificativa
<i>criterion</i>	gini,entropy, log_loss	Função para medir a qualidade de uma divisão. Os critérios suportados são "gini", "log_loss" e "entropy". Por <i>default</i> é o Gini.
<i>n_estimators</i>	100, 200	Define o número de árvores na floresta. Quantidades maiores tendem a melhorar a estabilidade e a capacidade de generalização do modelo.
<i>max_depth</i>	10, 20, 30	Controla a profundidade máxima das árvores. Limita a complexidade do modelo para evitar o <i>overfitting</i> .
<i>min_samples_split</i>	2, 5	Número mínimo de amostras para a divisão de um nó. Valores maiores tornam o modelo mais conservador, mitigando a influência de ruídos.
<i>class_weight</i>	balanced'	Ajusta os pesos das classes inversamente à sua frequência. Essencial para tratar o desbalanceamento severo de falhas raras.

Tabela 4: Espaço de Busca de Hiperparâmetros para XGB

Hiperparâmetros	Valores Testados	Descrição e Justificativa
<i>n_estimators</i>	100, 200	Define o número de árvores na floresta. Quantidades maiores tendem a melhorar a estabilidade e a capacidade de generalização do modelo.
<i>max_depth</i>	4,6,8	Controla a profundidade máxima das árvores. Limita a complexidade do modelo para evitar o <i>overfitting</i> .

<i>learning_rate</i>	2, 5	Controla a contribuição de cada árvore
<i>scale_pos_weight</i>	'balanced'	Razão entre negativos e positivos, substitui o SMOTE para controle em dados desbalanceados

3.5. Otimização com *Grid Search*, Validação Cruzada e Métricas de Avaliação

O *Grid Search* foi utilizado para avaliar todas as combinações dos hiperparâmetros indicados nas Tabelas 3 e 4 e, selecionar aqueles que apresentam o melhor desempenho segundo a métrica ROC-AUC.

Neste trabalho, o desempenho dos modelos foi avaliado utilizando as métricas: área sob a curva ROC (ROC-AUC), proporções predições positivas corretas e de casos positivos corretamente identificados (*Precision*, *Recall*), a Média harmônica entre precisão e recall (*F1-Score*) e a Proporção total de predições corretas (*Accuracy*) [Geron, 2025].

Para realizar a validação cruzada, o *dataset* foi dividido em 5 *folds*, e a cada iteração 4 *folds* foram usados para treino e um para validação, forçando a manutenção da proporção de classes em todos os *folds*. Essa tática promoveu uma avaliação mais confiável do desempenho do modelo com redução dos riscos de *overfitting* e melhor generalização.

Para a comparação entre cenários (RF, XGBoost e *Ensemble*), utilizou-se o mesmo conjunto de teste, assegurando a compatibilidade direta das métricas. O *Ensemble* corresponde à média das probabilidades previstas por RF e XGBoost. Adicionalmente, foi aplicado um processo de calibração utilizando *Platt Scaling* [Platt, 1999] avaliando a qualidade probabilística dos resultados.

4. Resultados Experimentais

O aparato experimental utilizado neste trabalho é composto por instância EC2 (g4.2xlarge) com 8 vCPUs, 32 GB RAM e 1 Nvidia GPU, rodando Ubuntu 22.04 LTS. Os *pipelines* foram desenvolvidos em Python (3.11.7) e bibliotecas *pandas* (2.3.3), *numpy* (1.26.4), *scikit-learn* (1.2.2), *xgboost* (2.0.3), *joblib* (1.2.0) e *flask* (3.0.0). Os artefatos, *datasets* e resultados experimentais estão disponíveis no Github do projeto.

4.1. Distribuição do *Dataset* por Horizonte Temporal

O *dataset* possui uma lista de 1.559 transformadores de potência com histórico de manutenção, a distribuição de falhas que depende do horizonte temporal analisado. Como esperado, horizontes temporais maiores concentram mais eventos de falha, que variaram em somente 50 equipamentos com falhas em 30 dias (3% da base), até 180 equipamentos com falhas em 90 dias (12%). Esta variação revela desbalanceamento de classes trazendo dificuldade para aprendizado em cada horizonte temporal.




Figura 1. Visualização da distribuição de falhas x total de equipamentos por horizonte temporal (30 a 90 dias).

4.2. Avaliação das *Features*

O critério da análise de importância das *features* pelo critério *Gini* do RF (Figura 2) confirma os fatores que influenciam falhas em transformadores. No RF, a principal *feature* é o tempo decorrido desde a última falha (*dias_desde_ultima_falha*), seguido pelo intervalo médio entre manutenções (*intervalo_medio_manut*) e pela idade do equipamento (*idade_dias*). No XGBoost, a idade aparece como principal preditor, seguido pelo percentil 90 de utilização (*p90_utilizacao*) e pelo limite de potência do equipamento.




Figura 2. Distribuição das *Features* mais importantes (50 dias)

A predominância de *features* diferentes entre o RF e XGBoost indica que os dois algoritmos observam sinais distintos, com o RF priorizando o histórico recente de operação problemática enquanto o XGBoost ao desgaste do equipamento ao longo do tempo, e ambos convergindo para a importância do histórico em detrimento a itens pontuais de utilização.

Features de tendência recente aparecem com maior importância no XGBoost do que no RF, especialmente *p90_utilizacao* e *delta_utilizacao*. Este comportamento indica que a técnica utilizada é mais sensível a dinâmicas de carga como “o que precede a falha”,

justificando a melhor performance dele em períodos de curto prazo. **FALTA**
DESCREVER A FIG 3




Figura 3. Mapa de calor das *features*

4.3. Avaliação e Desempenho: RF vs XGBoost vs *Essemble*

Os experimentos compararam RF, XGBoost e *Essemble* RF+XGBoost em todos os horizontes temporais. A Figura 4 apresenta o ROC-AUC de cada cenário por horizonte temporal de 30 a 90 dias.




Figura 4. ROC-AUC por horizonte – RF, XGBoost e *Essemble*

Conforme indica na Figura 4, o *Ensemble* superou o RF em 12 dos 13 horizontes temporais avaliados. O XGBoost indicou vantagem em horizontes temporais de curto prazo (35 e 45 dias), período em que a dinâmica recente de sobrecarga tem maior poder de influência, capturado de forma mais eficiente pelo *boosting* sequencial. O RF manteve desempenho mais estável e competitivo na janela de 50 a 55 dias, que representa o horizonte operacionalmente mais relevante para o contexto da NOS [ONS Procedimentos de Rede - Submódulo 16.2 2026]. A interpretabilidade dos resultados permite aos especialistas da NOS validar de forma preliminar tanto as *features* quanto a lógica preditiva do modelo. A capacidade de explicar quais fatores influenciam em cada cenário de predição agrega valor institucional ao processo de manutenção.

Tabela 5: Comparativo RF vs XGBoost vs *Essemble* ROC-AUC por Horizonte

Horizonte (d)	RF AUC	XGB AUC	<i>Ensemble</i> AUC	Δ XGB-RF	Δ Ens-RF
30	0,737	0,770	0,784	+0,033	+0,048
35	0,714	0,784	0,746	+0,070	+0,032

Horizonte (d)	RF AUC	XGB AUC	<i>Ensemble</i> AUC	Δ XGB-RF	Δ Ens-RF
40	0,754	0,698	0,753	-0,056	-0,001
45	0,642	0,743	0,691	+0,101	+0,049
50	0,770	0,740	0,783	-0,030	+0,013
55	0,688	0,726	0,711	+0,038	+0,023
60	0,604	0,655	0,635	+0,051	+0,031
65	0,583	0,629	0,612	+0,046	+0,029
70	0,581	0,627	0,605	+0,046	+0,024
75	0,586	0,642	0,631	+0,056	+0,044
80	0,571	0,596	0,586	+0,025	+0,015
85	0,609	0,586	0,620	-0,023	+0,011
90	0,607	0,641	0,640	+0,034	+0,033
Média	0,645	0,664	0,677	+0,030	+0,026

Como seria , FAVOR COMENTAR a interpretação das médias da tabela 5.

4.4. Curvas ROC dos melhores horizontes temporais

A Figura 5 apresenta as curvas ROC dos melhores horizontes individuais para os horizontes temporais. Observa-se que RF e *Ensemble* em 50 dias (AUC 0,77 e 0,783 respectivamente) e XGBoost em 35 dias (AUC = 0,784). As curvas confirmam que o *Ensemble* e o XGBoost produzem taxas de verdadeiros positivos superiores ao RF para qualquer limiar de decisão nos seus horizontes, o que traz na prática uma maior capacidade real de antecipar falhas com o menor nível de alarmes falsos.




Figura 5. Curva ROC dos melhores horizontes temporais.

4.5. Desempenho consolidado

A Figura 6 apresenta a *Precisão*, *Recall* e *F1-Score* para os três cenários ao longo dos horizontes, calculados sobre o conjunto de teste completo (30% estratificado de 1.559 equipamentos) para cada horizonte e modelo.




Figura 6. Precisão, Recall e F1-Score por horizonte temporal. (Threshold otimizado por F1; conjunto de testes completo)

4.6. Calibração de probabilidades RF

Em cenários normais, a saída de probabilidades de uma árvore na RF tende a ser superestimada, este comportamento tende a ser característico em florestas com árvores profundas. Para tornar as probabilidades interpretáveis em conceitos reais, aplicou-se *Platt Scaling* [Platt, 1999] sobre os modelos RF Treinados.

A Figura 7 apresenta os resultados desta calibração, o *Brier Score* médio foi reduzido em 13% sem impacto no ROC-AUC. O diagrama de confiabilidade (*Reliability Diagram*) confirma que o modelo não calibrado superestima o acontecimento da falha, e após a calibração uma saída de 0,7 do modelo representa 70% de chance real de falha no horizonte indicado. Requisito tal imprescindível para utilização do modelo em cenário produtivo no ONS.




Figura 7. Calibração via *Platt Scaling*: Brier Score por horizonte

5. Considerações Finais e Trabalhos Futuros

Este trabalho apresentou o ciclo de preparação do *dataset*, a construção da ferramenta Sin@lize, bem como o *benchmark* comparativo entre os modelos RF, XGBoost e sua união utilizando *datasets* com dados reais e procedimentos de rede do ONS, totalizando 39 modelos treinados e avaliados sobre 1.559 transformadores do SIN.

O horizonte temporal de 35 dias emergiu como o mais promissor em todas as métricas avaliadas. O *Ensemble* atingiu AUC de 0,784, F1-Score de 0.467 e Precisão de 0,778 indicando que ao acionar um alerta de falha com 35 dias de antecedência 3 em cada 4 alarmes correspondem a falhas reais e iminentes.

O XGBoost isolado também alcançou AUC de 0,784 e F1 de 0,452 em 35 dias, confirmando a relevância do *boosting* para curto prazo, e no horizonte temporal de 30 dias, o *Ensemble* registrou seu segundo melhor AUC (0,784), com precisão ainda mais elevada (0,364) com apenas 7 falsos positivos no conjunto de teste, sugerindo que a janela de 30 e 35 dias, concentra os sinais de degradação mais discriminativos presentes nas features.

Em termos médios, o *Ensemble* obteve ROC-AUC médio de 0,68 (RF: 0,645; XGBoost: 0,664) e F1-Score médio de 0,292 (RF: 0,254; XGBoost: 0,283) ao longo dos 13 horizontes. O desempenho decresce progressivamente nos horizontes mais longos (60–90 dias), onde a menor concentração de sinais precursores e o maior desbalanceamento relativo tornam a discriminação mais difícil. Esses resultados são coerentes com a literatura de manutenção preditiva em sistemas de potência. A calibração via *Platt Scaling* melhorou a qualidade probabilística em 13% (*Brier Score* médio: 0,098 até 0,085), tornando as probabilidades diretamente interpretáveis para priorização de intervenções no ONS.

Entre as principais contribuições deste trabalho destaca-se a metodologia, criação de *pipelines* de tratamento de dados brutos extraídos diretamente do SIN, gerando os *datasets* e *features*. Essa estratégia poderá ser adaptável para outros tipos de cenários, permitindo expandir o estudo para outros tipos de equipamentos do SIN, como linhas de transmissão, bancos de capacitores, equipamentos de controle reativo, e até mesmo na parte de geração com usinas e unidades geradoras.

Dentre as principais limitações destacamos a necessidade de carga de dados meteorológicos. Esses dados podem agregar novas *features* a serem analisadas, como temperatura média, vento, índice UV e até incidência de raios na região do equipamento. Outra possibilidade seria agregar os dados de monitoramento dos transformadores, como por exemplo, fabricante e *features* específicas ligadas aos seus equipamentos tais como temperatura e marca do óleo, e modelo de placa de comunicação. Destacamos que, devido à necessidade de descaracterização da localização dos ativos e da necessidade de anonimização dos clientes, esses dados não foram utilizados neste trabalho.

Referências

- [Glossário ONS 2025] OPERADOR NACIONAL DO SISTEMA ELÉTRICO (ONS). Glossário de termos do setor elétrico. Disponível em: <https://www.ons.org.br/paginas/conhecimento/glossario>. Acesso em: 10 nov. 2025.
- [ONS – sobre o ONS 2025] OPERADOR NACIONAL DO SISTEMA ELÉTRICO (ONS). Sobre o ONS Disponível em: <https://www.ons.org.br/paginas/sobre-o-ons/atualizacao> Acesso em 10 nov. 2025
- [ONS - que é o SIN 2025] OPERADOR NACIONAL DO SISTEMA ELÉTRICO (ONS). O que é o SIN? Disponível em: <https://www.ons.org.br/paginas/sobre-o-sin/o-que-e-o-sin> Acesso em: 10 nov. 2025.
- [ONS Procedimentos de Rede - Submódulo 2.1 2024] OPERADOR NACIONAL DO SISTEMA ELÉTRICO (ONS). Procedimentos de rede – submódulo 2.1 – Definição das re-des do Sistema Interligado Nacional Disponível em <https://www.ons.org.br/paginas/sobre-o-ons/procedimentos-de-rede/vigentes> Acesso em 13 nov. 2025.

- [ONS - SOM] OPERADOR NACIONAL DO SISTEMA ELÉTRICO (ONS). Síntese da operação mensal – disponível em: <https://www.ons.org.br/paginas/conhecimento/acervo-digital/documentos-e-publicacoes> Acesso em: 10 nov.2025.
- [ONS Procedimentos de Rede - Submódulo 16.1 2024] OPERADOR NACIONAL DO SISTEMA ELÉTRICO (ONS). Procedimentos de rede – submódulo 16.1 – Acompanhamento de manutenção – Visão Geral Disponível em <https://www.ons.org.br/paginas/sobre-o-ons/procedimentos-de-rede/vigentes> Acesso em 13 nov. 2025.
- [ONS Procedimentos de Rede - Submódulo 16.2 2026] OPERADOR NACIONAL DO SISTEMA ELÉTRICO (ONS). Procedimentos de rede – submódulo 16.2 – Acompanhamento de manutenção – Visão Geral Disponível em <https://www.ons.org.br/paginas/sobre-o-ons/procedimentos-de-rede/vigentes> Acesso em 1 mai. 2026.
- [Breiman 2001] Breiman, L. Random Forests. Machine Learning 45, 5–32 (2001). <https://doi.org/10.1023/A:1010933404324>
- [Matheus B. C. et al 2024] Fault Detection and Prediction for Power Transformers <https://www.mdpi.com/1996-1073/17/2/296>
- [Syeda T. Zahra et al., 2025] Power Transformer Health Index and Life Span Assessment: A Comprehensive Review of Conventional and Machine Learning based Approaches — Syeda T. Zahra et al., 2025
- [Chawla et al., 2002] Chawla, N.V., Bowyer, K.W., Hall, L.O., Kegelmeyer, W.P. SMOTE: Synthetic Minority Over-sampling Technique. Journal of Artificial Intelligence Research 16, 321–357 (2002). <https://doi.org/10.1613/jair.953>
- [Geron 2025] Hands-On Machine Learning with Scikit-Learn and Pytorch: Concepts, Tools, and Techniques to Build Intelligent Systems. O'Reilly Media. ISBN: 979-8-3416-0798-9 979-8-3416-0795-8.
- [Chen e Guestrin, 2016] Tianqi Chen and Carlos Guestrin. 2016. XGBoost: A Scalable Tree Boosting System. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16). Association for Computing Machinery, New York, NY, USA, 785–794. <https://doi.org/10.1145/2939672.2939785>